

Федеральное государственное автономное образовательное учреждение высшего образования
«НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ
«ВЫСШАЯ ШКОЛА ЭКОНОМИКИ»
Факультет экономических наук

ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА

Прогнозирование потребительской инфляции на недельных данных с учетом текстового анализа новостей

по направлению подготовки Экономика
образовательная программа «Экономика»

Выполнил:

Студент группы БЭК2211

Мирзоев Омар Мурадович

Ф.И.О.

Руководитель:

Станкевич Иван Павлович

степень, звание, должность Ф.И.О.

Москва 2026

ОГЛАВЛЕНИЕ

1	Введение	4
2	Обзор литературы	7
3	Данные	12
3.1	Сбор данных	12
3.2	Извлечение текстовых признаков	13
3.3	Итоговая обучающая выборка	19
4	Методы	21
4.1	Модели	21
4.2	Методы оценивания	22
4.3	Дополнительные инструменты	23
5	Оценивание моделей	25
5.1	Основное сравнение	25
5.2	Дополнительное тестирование	28
6	Обсуждение результатов	33
7	Заключение	38
	Список литературы	40

АННОТАЦИЯ

На сегодняшний день прогнозирование инфляции - одна из наиболее важных тем в макроэкономическом прогнозировании. Оно играет существенную роль в деятельности центральных банков, фирм и граждан и необходимо для обеспечения стабильного развития экономики государства. Поэтому в настоящее время исследуются различные способы улучшения качества прогноза. Один из них - учет информации из текстов новостей и комментариев к ним, которые могут заранее передавать сигналы о состоянии экономики, в то время как традиционные объясняющие переменные могут не сразу их улавливать. Несмотря на то, что уже существует множество исследований на эту тему, в основном в них используются месячные данные за большой промежуток времени, в течение которого характер зависимости может серьезно меняться. В данном исследовании был взят более маленький временной период в 10 лет, сохраняющий высокое количество наблюдений за счет недельной частоты данных. В работе были собраны тексты новостей за указанный период, далее из них был извлечен сентимент и использован как дополнение к классическим макроэкономическим индикаторам с целью улучшения качества прогнозирования.

1 Введение

Предсказание уровня цен является достаточно сложной задачей в условиях влияния многочисленных факторов, и за последнее время было проведено множество исследований, предлагающих возможные способы улучшения прогнозов. В особенности интерес к этой теме возрос относительно недавно, когда Банк Англии недооценил потенциальный уровень инфляции за период с 2021 по 2023 год, а затем пригласил бывшего главу ФРС, Бена Бернанке, чтобы получить объяснения и рекомендации по устранению ошибок (Pinson, 2026). Обзор Бернанке включал в себя критику традиционных методов прогнозирования в виде «всерной диаграммы», которые использовались Центральным банком, а также предложил несколько новых подходов. Данный обзор вызвал большое количество реакций среди макроэкономистов Великобритании (Aikman & Barwell, 2026), которые среди прочего отмечали необходимость использования методов, способных учитывать нелинейные процессы в данных и редкие экономические события.

Одним из таких способов улучшения прогнозов является исследование влияния сентимента новостных публикаций на уровень инфляции. Сегодня практически все события, происходящие в экономике, освещаются в СМИ без задержек. Довольно часто можно наблюдать, как перед ухудшением состояния экономики (например, сильным увеличением инфляции) новостной фон становится все более негативным, описывая возможный кризис. В то же время макропоказатели меняются не так быстро, а их публикация может задерживаться (Barbaglia, 2022). Поэтому учет новостных настроений может нести в себе информацию о предполагаемом движении инфляции и использоваться в дополнение к остальным признакам для ее прогнозирования.

Помимо самих текстов новостей довольно часто встречается секция комментариев к ним, где пользователи могут высказывать свою оценку происходящим событиям. Эти оценки могут также содержать полезную

информацию, например, об инфляционных ожиданиях населения. Такой способ извлечения информации не требует дополнительных ресурсов, в отличие от, например, опросов населения. Довольно редко встречаются исследования, где учитываются оба фактора (сам текст новостей и комментарии), что подчеркивает актуальность данной работы.

Несмотря на существенный прогресс в использовании сентимента новостей в прогнозных моделях, в случае инфляции они в основном оцениваются по периодам в 20-30 лет месячной или квартальной частоты. За это время в данных могут возникать структурные сдвиги, связанные с различными изменениями, происходящими в экономике, что усложняет обучение модели. Кроме того, довольно часто для прогнозирования используются эконометрические модели, которым достаточно сложно улавливать нелинейные зависимости в данных (Simionescu, 2025). Это может привести к менее качественным прогнозам или даже к отсутствию улучшений после добавления сентимента.

Главная цель исследования - определить, действительно ли сентимент-анализ новостей и комментариев к ним позволяет улучшить качество прогнозирования потребительской инфляции в условиях высокочастотных недельных данных. Для достижения поставленной цели в работе будут решаться следующие задачи: исследование существующей литературы по прогнозированию инфляции в целом и применению сентимент-анализа для улучшения прогнозов; сбор данных по недельной инфляции из публикаций Росстата; сбор текстов новостей и комментариев к ним за период с 2015 по 2025 год; извлечение сентимента из текстов при помощи моделей глубинного обучения; построение прогнозной ML-модели на основе недельного ряда макроэкономических показателей и извлеченного сентимента и сравнение результатов базовой (без учета новостного фона) и гибридной модели на тестовой выборке.

Решаемые задачи имеют как практическую, так и научную значимость. С одной стороны, предлагается новый подход к прогнозированию инфляции

на более частотных данных, что позволяет использовать модели машинного обучения, при этом не уходя совсем далеко во времени. С практической точки зрения, улучшение прогноза за счет добавления сентимента может быть полезно для осуществления более точной денежно-кредитной политики центральных банков, принятия решений в бизнесе, а также для домохозяйств с целью корректировки их инфляционных ожиданий.

У данного исследования также есть определенные ограничения. Так, в работе будет рассматриваться именно потребительская инфляция и результаты не могут распространяться на другие индексы цен. Кроме того, в данных будет использоваться промежуток времени в 10 лет, поэтому полученные результаты будут скорее относиться к современной экономике. Наконец, в отличие от текстов новостей, комментарии склонны содержать двусмысленные выражения, сарказм и другие факторы, усложняющие корректное извлечение сентимента.

2 Обзор литературы

Начать рассмотрение литературы по теме следует с более классических подходов к прогнозированию инфляции. Во-первых, необходимо определить, какие макроэкономические переменные обычно используются для анализа. Например, в работе Байбузы (2018) были использованы следующие регрессоры: индекс PMI (purchasing managers' index), цены на сырье, уровень безработицы и оплаты труда, различные процентные ставки и многие другие (всего более 90 переменных). Несмотря на то, что часто бывает сложно превзойти эконометрические бенчмарки (Joseph et al., 2024), основная гипотеза исследования заключалась в том, что в условиях большого количества объясняющих переменных модели машинного обучения смогут превзойти стандартные эконометрические модели. Чтобы проверить эту гипотезу, автор оценивает различные ML-модели (от Lasso-регрессии до ансамблевых методов) на данных месячной частоты за 2002-2018гг. Затем он сравнивает их качество прогноза с двумя бенчмарками: RW (random walk) и AR (autoregressive model).

Автор получил следующие результаты: ансамблевые методы (градиентный бустинг и случайный лес) показали лучшее качество с точки зрения метрики RMSE (root mean squared error) практически для всех горизонтов прогнозирования. Кроме того, комбинации эконометрических и ML-моделей во многих случаях приводили к улучшению качества прогноза. Такой результат согласуется с работой Medeiros et al. (2019), где авторы также пришли к выводу, что модели машинного обучения способны приближать более сложные зависимости в данных по инфляции при условии наличия большого количества признаков.

Переходя от классических показателей к сентименту, стоит отметить, что существуют разные способы его извлечения. Так, в работе Seo (2025) выделяются два способа обработки текста: обучаемые и необучаемые. Второй способ легче применять: он в основном опирается на словари,

подсчет слов и других статистик, которые не требуют наличия какой-то обучающей выборки. Автор далее рассматривает именно этот метод и предлагает его некоторое улучшение. В работе выделяются 15 основных секторов (производство, строительство и др.), а затем, если в предложении встретился определенный лексический шаблон из конкретного сектора, то оно вносит вклад в индекс соответствующего сектора. Далее автор использует полученные индексы для прогнозирования ВВП Кореи. В итоге исследование показывает, что учет этих индексов улучшает точность прогноза по сравнению с моделями, основанными только на экономических индексах. Также отмечается, что текстовый анализ работает особенно хорошо в краткосрочных прогнозах.

Что касается обучаемых методов, то здесь в основном используются алгоритмы глубинного обучения. Allard et al. (2024) продемонстрировали извлечение сентимента на датасете, включавшем в себя более 15 млн финансовых новостей за 1999-2023гг. В начале авторы фильтруют данные по ключевым словам в тексте, чтобы сократить обучающую выборку до приемлемого размера. Затем они используют большую языковую модель (GPT-4) для разметки небольшой части текстов на 3 категории: позитивный, негативный и нейтральный. Авторы столкнулись со следующей проблемой: большинство текстов относились к нейтральному классу, что дальше могло привести к переобучению под этот класс. Поэтому они провели аугментацию данных, то есть перефразирование текстов остальных классов без потери смысла с целью увеличения их веса в выборке. Далее на размеченных данных были обучены различные модели для предсказания сентимента уже для всех остальных новостей, и BERT-based модель лучше всего справилась с этой задачей. Затем вместо простого отнесения текстов к одному из классов были использованы вероятности принадлежности к каждому из них, которые позволяют посчитать матожидание. Такой подход учитывает ситуации, когда один текст может относиться сразу к нескольким категориям.

Извлекать sentimento можно и без использования LLM (Волгина, 2025). В своей работе автор вручную размечает 1000 новостей (из около 190000) на те же 3 категории. А дальше процедура совпадает с предыдущей статьей. Среди всех моделей, обученных на размеченном датасете, лучшее качество по критерию F1-меры показала комбинация RuBERT и логистической регрессии. Помимо sentimento автор также получает тему каждого текста, используя латентное размещение Дирихле (LDA). Наконец, в исследовании оцениваются различные модели для предсказания инфляции, и почти для всех из них добавление двух новых признаков (темы и sentimento) оказали положительное влияние на предсказательную силу.

В то же время существует большое количество проблем, которые могут возникать при анализе настроений в тексте. Например, в работе Eugster & Uhl (2024) авторы делят более 700 тыс. новостей основных агентств США на позитивные и негативные, а затем усредняют эти значения и получают sentimento новостей для каждого месяца. Но в статье делается важное замечание: в периоды относительно низкой инфляции негативные новости могут говорить о возможном еще более сильном снижении индекса цен, близком к дефляции, что также может вредить экономике. В то же время в периоды высокой инфляции уже позитивные новости скорее будут свидетельствовать о предполагаемом снижении цен. Поэтому для периодов, в которых инфляция была выше таргета Центрального банка авторы берут значение sentimento с отрицательным знаком. В результате исследования снова отмечается улучшение качества прогноза с учетом текстового анализа, однако с ростом горизонта прогнозирования влияние sentimento новостей становится все меньше, т.к. новости скорее отражают текущую ситуацию, которая может становится менее релевантной со временем.

Еще одна возможная проблема описывается в работе Rambaccussing & Kwiatkowski (2020). Здесь авторы ставят под сомнение надежность текстов новостей. Например, некоторые источники могут относиться к определенной политической партии, что может отражаться на публикациях. Еще стоит

учитывать возможные изменения в руководстве новостных агентств, которые также могут приводить к различным сдвигам в данных. А с увеличением периода рассмотрения возможность возникновения таких проблем только растёт. Поэтому авторы используют подход с фиксированными эффектами. Кроме того, они экспериментируют со способами извлечения сентимента из текста. Один из способов предлагал считать взвешенные значения сентимента, где вес определялся тем, как часто определенные ключевые слова (например, «инфляция») встречались в тексте. Второй подход заключался в нахождении наиболее часто встречающегося слова в тексте и присваивании его сентимента всей публикации. Таким образом авторы пытаются учитывать только наиболее релевантные новости.

Однако не только сентимент самих новостей может влиять на инфляцию. В работе Li & Tang (2022) авторы анализируют комментарии пользователей в Твиттере, которые были отобраны по ключевым словам, относящимся к инфляции. Кроме того, они также используют информацию из Google Trends, которая предоставляет собой статистику по поиску тех же ключевых слов. Обработка комментариев может быть более сложной задачей по сравнению с текстами новостей: в работе отмечается, что в комментариях используются ссылки, имена пользователей и другая информация, которая может повлиять на итоговое значение сентимента, но не имеет к нему отношения. Поэтому сначала авторы занимаются предобработкой подобных случаев. Далее снова используется BERT-based модель для извлечения настроений из текстов комментариев, которые потом добавляются в предсказательную модель и приводят к более высокому качеству прогноза.

Существует и много других исследований на эту тему, которые приводят к похожим результатам. Например, Sharpe et al. (2023) использовали отчеты из Зеленой книги ФРС вместо новостей. В этих отчетах представлены как точечные прогнозы, так и текстовое описание текущего состояния экономики. И далее авторы показывают, что эти описания сами по себе могут быть использованы не только для пояснения, но и для

корректировки прогноза. У Simionescu (2022) аналогичный результат получается для отчетов Национального банка Румынии. А в исследовании Tilly et al. (2021) результат обобщается для 10 стран Европы и Америки (Северной и Южной). Также стоит отметить, что сентимент-анализ может быть полезен не только для прогнозирования инфляции. Так, в работах Ashwin et al. (2024) и Li et al. (2016) улучшение прогноза после учета тональности новостей наблюдалось при исследовании ВВП и цен на нефть соответственно.

Обзор литературы можно обобщить следующим образом: существуют разные способы извлечь сентимент из текста, которые включают обучаемые и необучаемые методы. Также важно учитывать различные проблемы, которые могут возникать при его извлечении и дальнейшем использовании. Практически во всех исследованиях учет текстов новостей или комментариев приводил к улучшению качества модели. Наконец, ML-модели могут иметь более высокую предсказательную способность в случае большого числа наблюдений и признаков.

3 Данные

3.1 Сбор данных

Как уже было отмечено, одним из недостатков большинства исследований по прогнозированию инфляции являются длительные периоды рассмотрения. Обычно это связано с использованием данных месячной или квартальной частоты, которые требуют большого числа наблюдений для более точной оценки моделей. Однако за такие длинные промежутки времени состояние экономики может подвергаться серьезным изменениям: примерами могут послужить переход ЦБ к таргетированию инфляции в конце 2014г., переход к политике импортозамещения и т.д.

В данном исследовании будет рассмотрен достаточно актуальный промежуток времени (2015-2025гг.), но в то же время будет сохранено относительно большое количество наблюдений за счет перехода к недельной частоте. Для этого изначально вручную были собраны данные о потребительской инфляции из еженедельных публикаций Росстата. Всего в обучающую выборку попало 560 наблюдений, описывающих каждую неделю, начиная с 1 января 2014г. по 22 декабря 2025г. Динамику потребительской инфляции в России (с поправкой на сезонность) за указанный период можно наблюдать на рисунке 1.




Рис. 1. Динамика недельной потребительской инфляции в России за 2015-2026гг.

Источник: расчеты автора

На графике можно заметить резкие скачки, которые в основном возникают в первую неделю января или июля. В первом случае рост связан с вступлением в силу различных новых законов (например, об увеличении ставки по НДС), а во втором - с индексацией тарифов. Далее эти наблюдения будут учтены при формировании признаков в прогнозных моделях. Также можно заметить значительный рост инфляции в начале 2022г., который связан с началом СВО и введением различных санкций.

В дополнение к самой инфляции были собраны различные макроэкономические объясняющие переменные: ключевая ставка, MIIACR, цены на нефть марки Brent, газ, пшеницу, курс доллара к рублю, индекс Мосбиржи, денежный агрегат M0, индекс PMI (Purchasing Managers' Index), а также лаги этих переменных и самой инфляции. Некоторые из этих индексов были доступны на дневном уровне, поэтому они агрегировались средним по каждой неделе. Другие показатели (ставка ЦБ, PMI, M0) были доступны только для месячной частоты, поэтому здесь одно значение могло присваиваться всем наблюдениям внутри месяца.

Далее за указанный период были также собраны тексты новостей и комментариев к ним из сообщества ВКонтакте «Коммерсантъ Экономика». Сбор осуществлялся при помощи API VK. К новостным текстам были также добавлены новости с сайта новостного агентства «Интерфакс» по разделу «Новости экономики», которые собирались при помощи инструментов парсинга. В результате удалось получить более 100 тысяч новостных публикаций и более 50000 комментариев.

3.2 Извлечение текстовых признаков

Далее из полученных текстов необходимо было извлечь сентимент. В случае с новостными публикациями стояла задача извлечь скорее не эмоциональную составляющую (очевидно, что новости в основном пишутся в нейтральном стиле), а тематику относительно влияния этой новости на состояние экономики: позитивное, негативное или нейтральное.

Как было отмечено в обзоре литературы, наиболее информативные признаки из текстов можно получить при помощи supervised-методов, которые требуют обучения некоторых моделей. Причем в данном случае не получится взять готовую модель, так как задача довольно специфичная: тексты являются новостными публикациями, имеют экономическую направленность, а также необходимо извлечь именно смысл, а не тональность, как это обычно делается.

Для этого на сегодняшний день можно воспользоваться большими языковыми моделями (LLM), которые способны решать подобные задачи, однако процесс разметки данных с их помощью достаточно долгий. Кроме того, бесплатный доступ к API позволяет делать только ограниченное количество запросов. Поэтому было принято решение разметить только часть новостей, а далее обучить собственную модель для извлечения смыслового сентимента из текстов экономических новостей, которая позволит получить сентимент для всех остальных текстов.

Для разметки текстов была использована модель «GigaChat 2 Lite», а промпты отправлялись в виде API-запросов. В запросе содержался текст новости, а также требовалось ответить одним словом, какое влияние эта новость имеет на экономику (positive, negative, neutral). В условиях бесплатных ограничений всего удалось обработать около 8000 текстов, которые были выбраны случайно.

Полученные значения оказались достаточно сбалансированными (см. рис. 2), с небольшим преобладанием нейтрального класса, что говорит о хорошей разнородности выборки, благоприятной для обучения моделей. Далее выборка была разделена на обучающую, валидационную и тестовую в соотношении 80:10:10. Валидационная выборка использовалась для отслеживания переобучения, которое особенно вероятно при обучении более сложных моделей.




Рис. 2. Распределение значений сентимента в выборке по классам

Источник: расчеты автора

Далее было необходимо обучить на этих данных модель для предсказания сентимента. Для начала собранные тексты были тщательно обработаны: были очищены различные ссылки, лишние пробелы, специальные символы и прочая лишняя информация, которая не имеет отношения к содержанию текста. Также были удалены источники, даты, указания городов, которые могли бы запутать модель. Сначала были обучены базовые модели на более простых признаках (логистическая регрессия на bag-of-words и tf-idf, а также градиентный бустинг на word2vec + PCA). В качестве более продвинутых методов были также использованы BERT-based модели (Devlin et al.), а именно ruBERT и ruRoBERTa. Эти модели являются уже предобученными на большом количестве русскоязычных текстов, поэтому оставалось только дообучить их под данную задачу. Качество моделей сравнивалось по критериям accuracy (доля верных ответов) и F1-меры (см. таблицу 1).

Как видно из таблицы, лучшее качество показывает модель ruRoBERTa, поэтому именно она дальше была использована для извлечения сентимента всех остальных новостей. Также стоит отметить сильный прирост в качестве по сравнению с более простыми моделями. Это, скорее всего, связано с тем, что BERT-based модели являются уже предобученными и

способны учитывать контекст предложений, а не только частоту встречаемости слов.

	CatBoost (word2vec)	LogReg (TF-IDF)	LogReg (bag-of-words)	ruBERT	ruRoBERTa
Accuracy	0.426	0.501	0.543	0.693	0.761
F1-macro	0.22	0.501	0.527	0.694	0.762

Таблица 1. Сравнение качества моделей для прогнозирования сентимента новостей.

Примечание: в случае с логистической регрессией и градиентным бустингом выставлены параметры по умолчанию; черным выделена лучшая по качеству модель.

Источник: расчеты автора

Дальше из полученных значений сентимента были сформированы различные признаки, такие как доля позитивного и негативного сентимента за неделю, разница между максимальным и минимальным значением за неделю, а также скользящее среднее за последние 4 недели (см. рисунок 3).




Рис. 3. Динамика доли позитивных и негативных новостей за неделю (скользящее среднее за последний месяц).

Источник: расчеты автора

Как видно из графиков, данные показатели являются достаточно волатильными, что кажется логичным результатом в условиях недельной

частоты. Можно наблюдать пики негативного (и резкие провалы позитивного) сентимента в начале 2020 и 2022гг, связанные с соответствующими кризисами. Однако за резкими изменениями сразу следует восстановительная динамика.

Также следует представить по несколько примеров из выборки для каждого класса.

Положительные:

- 1) *«Рынок акций РФ в четверг возобновил подъем вместе с мировыми площадками после известий о подписании торгового соглашения первой фазы между США и Китаем...»;*
- 2) *«Многие сельхозкультуры дали ранний урожай, цены начали снижаться раньше обычного...»;*
- 3) *«Президент Владимир Путин проводит совещание по экономическим вопросам правительством. Он заявил, что фактическая динамика экономики России в 2022 году оказалась лучше многих прогнозов.»*

Негативные:

- 1) *«Туроператоры ждут сокращения турпотока в регионах вдвое из-за введения новых ограничений для борьбы с COVID-19, спад продаж затронет осенние школьные каникулы и новогодние праздники, заявила Ассоциация туроператоров России (АТОР).»;*
- 2) *«Минувшую неделю рубль завершает сильнейшим за последние месяцы ослаблением позиции относительно ведущих мировых валют. По итогам торгов пятницы курс доллара на Московской бирже составил 92,90 руб./\$, что на 2,3 руб. выше значений закрытия конца предшествовавшей недели.»*
- 3) *«Налоговый потенциал регионов используется не в полном объеме — к такому выводу пришла Счетная палата (СП), проанализировавшая ситуацию в 12 дотационных территориях РФ...»*

Помимо текстов новостей также было необходимо учесть и соответствующие комментарии. Здесь, в отличие от новостных публикаций, целью было извлечь именно эмоциональную составляющую, которая бы

описывала реакцию людей на происходящие события и могла бы служить оценкой их мнений и ожиданий. Для подобных задач уже существует большое количество готовых моделей, поэтому было принято решение использовать именно их. Всего использовалось две модели: первая модель - это ruBERT, дообученный на извлечение токсичности из комментариев пользователей в социальной сети «Одноклассники» (измеряется по шкале от 0 до 1), вторая модель - тот же ruBERT, но уже настроенный на извлечение тональности (positive, negative, neutral) и обучавшийся на большом количестве русскоязычных отзывов и новостей.

По аналогии с новостями рассмотрим примеры позитивных, негативных, а также наиболее токсичных комментариев.

Позитивные:

- 1) *«Экономика развивается, если население способно покупать. Мы видим только падение покупательской способности людей и рост цен на товары и услуги. Оба процесса имеют отрицательный эффект.»*
- 2) *«Вот наглые россияне получают сто тысяч, а платить по счетам не хотят.»*
- 3) *«Фейковый показатель. Никакого ожидания нет. Население тупо получает инфляцию как рост цен как итог удорожания цен на ставку ЦБРФ плюс темп разрушения рубля плюс рост цен и тарифов монополий.»*

Негативные:

- 1) *«В плане долговых обязательств у нас все просто шикарно, в стране есть резервы чтобы одновременно все покрыть. Так что от мировой нестабильности в финансах мы застрахованы получше, чем 99% стран.»*
- 2) *«Отлично 🍌. Продовольственная безопасность обеспечена и на продажу за рубеж хватит.»*
- 3) *«хорошая инициатива»*

Наиболее токсичные (по выдаче модели):

*«Их лучше расстрелять»; «В ж**у таких аналитиков»; «Когда уже эта еб**о с***ёт в туман?»; «На кол»; «Да скоро вообще ни***ц будет»*

Далее для полученного сентимента и значений токсичности были извлечены аналогичные признаки, что и для новостей. Основное различие между двумя видами текстов заключается в информации, которую они передают: новости больше характеризуют состояние экономики в целом, а комментарии - реакцию и мнение людей.

3.3 Итоговая обучающая выборка

Собранные макропеременные и новые текстовые признаки были объединены в один датасет, который будет использован для обучения прогнозных моделей. В обучающую выборку вошли следующие наборы признаков:

1) *Состояние внутренней экономики*: `cb_rate` (ключевая ставка, %, мес.); `miacr` (ставка MIACR, %, нед.), `m0` (денежный агрегат M0, индекс, мес.), `pmi` (индекс PMI, мес.), а также лаги этих переменных и самой инфляции

2) *Товарно-сырьевые факторы*: `brent` (цены на нефть марки Brent, \$, нед.), `gas` (цены на природный газ, \$, нед.), `wheat` (цены на пшеницу, \$, нед.), лаги указанных переменных

3) *Финансовый и валютный рынок*: `dollar` (курс доллара к рублю, нед.), `moex` (индекс Мосбиржи, % к пред. нед.), а также их лаги.

4) *Сезонные*: `first_july` (является ли неделя первой неделей июля, бинарная), `first_january` (является ли первой неделей января, бинарная), `week_length` (длина недели), `month_sin` (синус от номера месяца в году), `month_cos` (косинус от номера месяца в году)

5) *Текстовые*: `pos_com`, `neg_com`, `pos_news`, `neg_news` (доля позитивных/негативных новостей/комментариев за неделю), а также их `range` (разница между максимумом и минимумом за неделю) и `wind` (скользящее среднее за последние 4 недели).

После подсчета всех признаков в выборке осталось 541 наблюдение и 52 регрессора. Все ряды были скорректированы на сезонность при помощи

STL-декомпозиции, а также проверены на стационарность при помощи теста Дики-Фуллера, и в случае нестационарности на уровне значимости 0.05 бралась первая разность. Выборка была разделена на обучающую и тестовую по времени: в качестве основного тестового периода был выбран 2025г. (50 наблюдений).

4 Методы

4.1 Модели

В рамках данного исследования необходимо определить модели, при помощи которых будут формироваться прогнозы инфляции. В качестве бенчмарков в данной работе используются классические эконометрические модели временных рядов: Random Walk (или наивный прогноз), ETS, AR, MA, и ARIMA. Эти модели строят прогноз только на основе предыдущих значений (лагов) целевой переменной и позволяют определить базовый уровень точности в контексте данной задачи. Сравнение с бенчмарком позволяет определить, имеет ли смысл учитывать дополнительные признаки. В качестве примера приведем формулу для прогноза модели ARIMA(p, d, q) для ряда, который является интегрированным некоторого порядка d:

$$y_t = \alpha + \beta_1 y_{t-1} + \dots + \beta_p y_{t-p} + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q}$$

Существует также модификация данной модели, ARIMAX, которая позволяет учитывать еще и экзогенные переменные. Однако зачастую в условиях большого количества наблюдений в обучающей выборке ML-модели оказываются более точными. В качестве более простой модели машинного обучения была использована Ridge-регрессия, которая, в отличие от обычной линейной регрессии, позволяет бороться с переобучением, путем добавления параметра регуляризации в функцию потерь:

$$L(w) = \|Xw - y\|^2 + \lambda \|w\|^2$$

Однако в данных часто могут наблюдаться нелинейные зависимости между целевой переменной и регрессорами. Для этого в работе также использовались ансамблевые ML-модели, а именно Random Forest (случайный лес) и градиентный бустинг в реализации CatBoost. Оба этих алгоритма являются комбинацией базовых моделей, в качестве которых используются решающие деревья. Отдельное дерево решений строится

рекурсивно: на каждом шаге подбирается признак и порог, по которым выборка разбивается на части так, чтобы минимизировать некоторый критерий «хаотичности». Например, в случае задачи регрессии в качестве этого критерия используется дисперсия, а для задачи классификации - энтропия. Именно за счет такого построения подобные модели могут приближать нелинейные зависимости. После полного построения дерева в качестве прогноза обычно используется среднее значение целевой переменной среди объектов обучающей выборки в вершине, в которую попал данный объект.

В случае со случайным лесом базовые модели (деревья) строятся независимо друг от друга, а финальный прогноз формируется путем простого усреднения. В градиентном бустинге деревья строятся последовательно: каждое последующее дерево обучается исправлять ошибки композиции с предыдущего шага. А в качестве итогового прогноза используется сумма прогнозов базовых моделей.

Еще одним нелинейным алгоритмом машинного обучения, который был использован в данной работе, является KNN (K-Nearest Neighbors). Данный метод является метрическим: для того чтобы выдать прогноз на новом объекте сначала определяются k объектов из обучающей выборки, наиболее близких к нему по некоторой метрике (обычно это евклидово расстояние). А дальше финальный прогноз - это среднее значение целевой переменной среди этого множества ближайших соседей. Таким образом, прогнозные модели можно разделить на несколько групп: стандартные бенчмарки, основанные на лагах самой инфляции; линейные модели, учитывающие дополнительные признаки; а также нелинейные ML-модели.

4.2 Методы оценивания

Упомянутые выше модели далее использовались для предсказания текущего или будущего (с различными горизонтами прогнозирования) уровня инфляции. В случае с эконометрическими моделями прогноз

формировался рекурсивно при помощи расширяющегося окна: сначала составлялся прогноз для первой недели из тестовой выборки, а дальше фактическое значение инфляции на этой неделе использовалось для обновления модели на следующем шаге и так далее в хронологическом порядке. Это делалось для того, чтобы модель могла использовать как можно больше точной информации, известной к текущему моменту. Параметры подбирались автоматически по AIC-критерию.

Для ML-моделей прогноз формировался один раз, однако здесь в качестве признаков использовались фактические лаги инфляции с прошлых недель, что позволяет сравнивать их с эконометрическими: оба типа моделей при предсказании текущего уровня инфляции наблюдают фактические значения из прошлого. Гиперпараметры для ML-моделей были выставлены по умолчанию.

4.3 Дополнительные инструменты

Помимо самих моделей в работе для различных целей были использованы дополнительные инструменты. Например, для проверки значимости различий в точности прогнозов моделей использовались статистические тесты Диболда-Мариано и Джакомини-Уайта. Тест Диболда-Мариано проверяет нулевую гипотезу о том, что точность прогнозов двух моделей совпадает:

$$H_0: E \left(f \left(e_t^{(1)} \right) - f \left(e_t^{(2)} \right) \right) = 0 ,$$

где $e_t^{(i)} = y_t - \hat{y}_t^{(i)}$, т.е. разность фактического значения и прогноза, а $f(.)$ - некоторая функция от этой разности (в нашем случае - MAE). Статистика данного теста имеет асимптотически нормальное распределение, поэтому дальше по нему рассчитывается p-value и делается вывод: если нулевая гипотеза отвергается, то различия в качестве значимы на соответствующем уровне значимости.

Тест Джакомини-Уайта имеет похожую структуру, однако является скорее обобщением теста Диболда-Мариано. Основное отличие заключается в том, что здесь оценивается условная прогнозная способность, так как нулевая гипотеза формулируется через условное ожидание функции потерь. Здесь для расчета статистики уже используется распределение Хи-квадрат. Кроме тестов в работе также использовались методы локальной интерпретации, о которых будет подробнее расписано в разделе про обсуждение результатов.

5 Оценивание моделей

5.1 Основное сравнение

Относительно большое количество наблюдений в данном случае позволяет обучать ML-модели, которые способны улавливать более сложные зависимости в данных за счет своей нелинейности. Как уже было отмечено, в рамках данного исследования были оценены следующие модели, способные учитывать дополнительные признаки помимо лагов самой целевой переменной: Ridge-регрессия, ARIMAX, KNN, Random Forest и CatBoost. Результаты моделей сравнивались на тестовой выборке на основе средней абсолютной ошибки (MAE), а значимость различий проверялась при помощи тестов Диболда-Мариано и Джакомини-Уайта.

Для начала были оценены упомянутые ранее стандартные эконометрические бенчмарки, которые не учитывают экзогенные переменные. Среди них лучшее качество показала ARIMA(1, 0, 2), ошибка на тестовой выборке составила 0.059 (см. рисунок 4). Поэтому дальше все остальные модели будут сравниваться с этим бенчмарком.




Рис. 4. Сравнение прогноза и фактических значений инфляции (с учетом сезонности) для модели ARIMA

Источник: расчеты автора

Далее были оценены модели, которые учитывают дополнительные объясняющие переменные. Для каждой из них использовались две обучающие выборки: без текстовых переменных и с их включением, затем для них считались ошибки и сравнивались между собой. Результаты этой процедуры представлены в таблице 2.

	MAE_ARIMA (benchmark)	MAE_no_text	MAE_with_texts	Изменение, %	p-value GW	p-value DM
Ridge	0.059	0.061	0.06	-1.52	0.68	0.95
ARIMAX	0.059	0.068	0.069	+1.25	0.86	0.91
KNN	0.059	0.06	0.052	-13.27	0.08	0.39
CatBoost	0.059	0.058	0.052	-10.197	0.03*	0.099
Random Forest	0.059	0.051	0.045	-13.12	0.008**	0.16

Таблица 2. Сравнение изменений в качестве после добавления текстовых признаков.

Примечание: черным выделено минимальное значение ошибки; * $p < 0.05$; ** $p < 0.01$;

*** $p < 0.001$

Источник: расчеты автора

Из таблицы следует, что для всех моделей, кроме ARIMAX, наблюдалось фактическое снижение ошибки. Больше всего ошибка снизилась у KNN и случайного леса (-13.27% и -13.12% соответственно). Согласно тесту Джакомини-Уайта, статистически значимое улучшение наблюдается для ансамблевых методов (CatBoost и RF) на уровнях значимости 0.05 и 0.01. На уровне значимости 0.1 можно сделать вывод об улучшении в качестве и для KNN. В то же время тест Диболда-Мариано говорит об отсутствии значимых изменений практически для всех моделей (за исключением бустинга на уровне 0.1).

Из таблицы можно сделать вывод о том, что новые текстовые переменные скорее являются полезными для более сложных моделей, что может быть связано с нелинейной зависимостью в данных. В частности,

достаточно сильные изменения наблюдаются для случайного леса, что позволяет добиться минимального значения ошибки из всех представленных (см. рис. 5).




Рис. 5. Сравнение прогноза и фактических значений инфляции (с учетом сезонности) для модели Random Forest, оцененной по всем признакам, включая текстовые

Источник: расчеты автора

Далее аналогичным образом качество моделей с признаками на основе сентимента было сравнено с бенчмарком. Результаты сравнений представлены в таблице 3. Здесь можно заметить, что бенчмарк превосходят по качеству именно нелинейные модели (KNN, бустинг и случайный лес). В то же время линейная регрессия и ARIMAX уступают бенчмарку по качеству (причем, как с текстовыми признаками, так и без них), что является еще одним аргументом в пользу того, что в данных могут быть более сложные, нелинейные взаимосвязи. Также следует отметить значительное снижение ошибки по сравнению с ARIMA в случае с моделью случайного леса (почти 25%).

	MAE_ARIMA (benchmark)	MAE_with_texts	Изменение, %	p-value GW	p-value DM
Ridge	0.059	0.06	+2.06	0.43	0.18
ARIMAX	0.059	0.069	+16.7	0.27	0.3
KNN	0.059	0.052	-12.17	0.35	0.14
CatBoost	0.059	0.052	-11.5	0.35	0.1
Random Forest	0.059	0.045	-24.41	0.38	0.09

Таблица 3. Сравнение оцененных моделей с бенчмарком. Примечание: черным выделено минимальное значение ошибки и наибольшее снижение ошибки

Источник: расчеты автора

5.2 Дополнительное тестирование

Для того чтобы проверить устойчивость полученных результатов, были опробованы различные наборы обучающей и тестовой выборок. Для тестирования поочередно брались данные с 2020 по 2024гг., а обучение для каждого случая проводилось на данных до года тестирования. В таблице 4 для каждого года в случае, если наблюдались улучшения после добавления текстовых признаков, представлено p-value для соответствующего теста Диболда-Мариано. В противном случае ставится прочерк.

Из данной таблицы видно, что для ансамблевых методов (бустинг и случайный лес) улучшения наблюдаются во все годы, однако значимые изменения (хотя бы на уровне 0.1) можно наблюдать только для 2020 и 2022гг. (в случае с бустингом также добавляется и 2021г.). Также можно заметить, что для линейных моделей (Ridge-регрессия и ARIMAX) текстовые признаки устойчиво оказываются бесполезными: значимые улучшения наблюдаются только для ARIMAX в 2020г. В то же время для KNN снижение ошибки либо не наблюдалось, либо оказывалось незначимым. В целом можно сделать вывод об устойчивости результатов к изменению тестового периода для ансамблевых методов, причем значимые улучшения чаще

наблюдаются для более беспокойных, шоковых годов (2020г. и 2022г.). Это может говорить о том, что признаки на основе сентимента новостей и комментариев намного раньше реагируют на различные изменения в экономике и позволяют моделям улавливать сигналы о шоках и колебаниях, в то время как макропеременные меняются с задержкой.

	2020	2021	2022	2023	2024
Ridge	-	-	-	-	-
ARIMAX	0.009**	-	-	0.23	-
KNN	-	-	0.17	-	0.7
CatBoost	0.03*	0.08	0.09	0.3	0.57
Random Forest	0.065	0.92	0.057	0.83	0.83

Таблица 4. P-value для теста о значимости улучшений в качестве прогноза после добавления текстовых переменных (в случае, если улучшений нет, ставится прочерк; жирным выделены значения меньше 0.1)

Источник: расчеты автора

Для того чтобы рассмотреть поведение моделей внутри тестового периода, на примере 2020, 2022 и 2025гг. они были разбиты по кварталам. Модели обучались последовательно при помощи расширяющегося окна: например, после тестирования на первом квартале, он попадал в обучающую выборку для тестирования на следующем и так далее. Полученные результаты, а также характеристики (среднее, стандартное отклонение) каждого квартала представлены в таблице 5. Из таблицы можно сразу сделать вывод, что наблюдаемые ранее улучшения для некоторых моделей и определенных лет далеко не всегда можно заметить на протяжении всех кварталов. Такое можно заметить только для нелинейных моделей (RF,

CatBoost и KNN) и 2025г. в качестве тестового, в остальных же случаях результаты разнятся от квартала к кварталу.

Также следует отметить третий квартал 2020г. и первый квартал 2022г., в которых для всех моделей наблюдается ухудшение качества прогноза (за исключением незначительного повышения для CatBoost Q1/2022), в том числе максимальное увеличение (+31%) для KNN. В первом случае, возможно, ухудшение связано со снижением среднего уровня инфляции, хотя сентимент на фоне коронакризиса был негативный. А во втором случае, вероятнее всего, причина ухудшений заключается в том, что моделям не хватило подобных примеров с резкими скачками на этапе обучения, так как далее на примере 2025г. уже видно, что относительно высокий разброс не мешает ML-моделям извлекать пользу из текстовых признаков.

	2020				2022				2025			
	Q1	Q2	Q3	Q4	Q1	Q2	Q3	Q4	Q1	Q2	Q3	Q4
<i>Mean</i>	0.07	0.1	0.09	0.12	0.77	0.18	0	0.08	0.19	0.11	0.13	0.07
<i>Std</i>	0.09	0.08	0.07	0.03	0.84	0.33	0.09	0.12	0.11	0.02	0.19	0.03
Ridge	-10.8	4.2	15.5	5.3	5	1.1	-3.8	-1.7	0	3.4	-0.7	3
ARIMAX	-23.5	-33	-27	-30	5.9	-0.7	-4.2	-0.8	-2.8	6.9	4.1	8
KNN	10.6	16.4	31	-21	1.6	17.9	-15	24.2	-19	-19	-28	-36
CatBoost	-4.3	4.3	5.1	-4.9	-0.1	-2.5	-7.1	1.6	-18	-11	-7.7	-7
Random Forest	-6.4	-9	4.7	3.9	1.8	-8.8	-4.1	3.4	-7	-6.3	-4.3	-14

Таблица 5. Процентное изменение квартальной ошибки после добавления текстовых признаков для некоторых годов, а также среднее и стандартное отклонение инфляции по кварталам.

Источник: расчеты автора

Из особенностей поведения моделей по кварталам можно заметить высокую волатильность изменений для KNN: данная модель достигает как минимального, так и максимального значения среди всех. Для ARIMAX

значительные улучшения наблюдаются в 2020г., а в случае с Ridge-регрессией снижение ошибки довольно редко и в основном незначительно, что согласуется с полученными ранее выводами. В то же время для ансамблевых моделей можно получить уточнение к предыдущим результатам: довольно часто улучшение в качестве прогноза при тестировании целиком на конкретном году объясняется скорее пересиливанием улучшения на некоторых кварталах, а не устойчивым снижением ошибки везде: это особенно заметно на примере 2022г.

Для более детального рассмотрения были также оценены прогнозы на разные горизонты: 1, 2, 4, 8, 16 и 24 недели вперед. Модели обучались предсказывать значение инфляции в период $t+k$ по данным до периода t включительно. В качестве тестового периода были выбраны 2023-2025гг. (см. таблицу 6). Здесь можно также заметить несколько дополнений к полученным ранее результатам. Так, для всех тестовых периодов довольно часто модели достигают наибольшего снижения ошибок на более высоких горизонтах прогнозирования. Например, максимальное снижение (-37.2%) наблюдалось для Random Forest в 2023г. при прогнозе инфляции на 3 месяца вперед. Однако если учитывать именно сам факт снижения ошибки, то наиболее благоприятным в этом плане становится горизонт в 2 недели. Таким образом, более стабильный положительный эффект от добавления признаков на основе сентимента наблюдается в краткосрочной перспективе, а наибольшие по модулю улучшения в отдельных случаях - для более высоких горизонтов.

Также следует отметить устойчивое отсутствие пользы от текстовых признаков для ARIMAX в 2024-2025гг, хотя в 2023г. можно наблюдать улучшения почти для всех горизонтов, что согласуется с результатами при наукастинге. У нелинейных моделей снижение ошибки наблюдается чаще, что еще раз может подтверждать нелинейный характер влияния сентимента. В целом следует подчеркнуть, что, если при наукастинге ранее не наблюдалось значимых улучшений в качестве для 2023-2024гг., то при

увеличении горизонта прогноза процентное снижение ошибки для некоторых моделей становится значительным. Кроме того, из таблицы видно, что нет ни одной модели, для которой качество повышалось бы на всех горизонтах. Это говорит о том, что учет текстовой информации не универсален и польза от него скорее зависит от конкретной ситуации.

Год	Горизонт Модель	T+1	T+2	T+4	T+8	T+16	T+24
2025	Ridge	-2.6	11.6	4.6	-2.5	-13.8	-8.6
	ARIMAX	2.2	2.7	2.5	4.9	5.9	5.3
	KNN	1	-5.7	-5.8	-2.6	7.6	7.9
	CatBoost	-2.5	-3.3	-3.1	1.9	-7.2	-10
	Random Forest	1.01	-6.8	3.7	-2.6	-12.7	-0.03
2024	Ridge	0.7	-0.2	0.4	-0.4	-2.3	7.2
	ARIMAX	3.5	3.3	2.5	3.3	4.1	1.9
	KNN	-2.6	-10	-0.1	-1.2	2.5	-23.4
	CatBoost	-14.4	-8.4	8.1	12.3	4.8	-11.9
	Random Forest	1.4	-7	-8.8	9.1	22.7	6.6
2023	Ridge	-2.5	-3.1	-1.9	0.3	0.8	1.1
	ARIMAX	-2.3	-1.7	-1.4	-1.4	-0.9	0.8
	KNN	-1.5	3	7.4	3.1	-2.2	-0.2
	CatBoost	-3.1	-4.2	-1.1	9.3	-1.4	-1.6
	Random Forest	0.2	-7.5	-1.8	22.1	-37.2	-9

Таблица 6. Процентное изменение ошибки для разных горизонтов после добавления текстовых признаков для 2023-2025гг. (жирным выделено максимальное снижение ошибки для данного горизонта и года)

Источник: расчеты автора

6 Обсуждение результатов

Как можно было заметить ранее, нелинейные модели во многих случаях показывали статистически значимо лучшие результаты. В частности, минимальное значение ошибки на тестовой выборке из 2025г. достигалось для модели случайного леса. Поэтому возникает интерес в интерпретации работы данной модели. В отличие от линейных моделей, ансамблевые методы не позволяют напрямую оценить характер влияния конкретного признака на прогноз, однако существуют различные методы интерпретации, позволяющие это сделать.

Для начала стоит обратить внимание на важность признаков (feature importance), которая считается на основе суммарного снижения информационного критерия по данному признаку для всех деревьев в ансамбле. Далее значения нормализуются в диапазон от 0 до 1, и итоговая сумма важностей признаков равна 1.




Рис. 6. Топ-10 наиболее важных признаков для Random Forest

Источник: расчеты автора

Из графика видно, что в первую очередь модель обращает внимание на денежную массу и первый лаг самой инфляции. Также стоит отметить, что в

пятерку наиболее важных регрессоров входит скользящее среднее доли негативных новостей, что в очередной раз подчеркивает пользу учета текстовой информации для модели. Довольно важным признаком оказывается и индекс Мосбиржи, который так же, как и сентимент, довольно быстро реагирует на различные изменения и шоки. Однако недостатком такого метода интерпретации является то, что он не позволяет понять характер влияния признака в конкретной точке.

Для решения этой проблемы существуют методы локальной интерпретации. Так, в работе Aras & Lisboa (2022) авторы раскрывают смысл прогнозов инфляции в Турции при помощи метода SHAP. Например, авторы понимают, что в случае с пандемией COVID-19 прогноз формируется из лагов самой инфляции, а в более спокойные периоды высокое влияние имеет курс доллара, что связано с высокой импортозависимостью страны.

Другой метод локальной интерпретации - LIME (Local Interpretable Model-agnostic Explanations). Для отдельного объекта здесь генерируются похожие на него наблюдения, исходная модель выдает на них прогнозы, а дальше на предсказанных значениях обучается уже интерпретируемая модель. В прошлом разделе было показано, что текстовые признаки особенно полезны для модели в более нестабильные годы. Поэтому в качестве примеров для интерпретации интересно рассмотреть различные шоки, и понять, за счет чего модель выдает именно такой прогноз.

В таблице 4 представлена интерпретация для недели по 6 апреля 2020г., когда проявились различные последствия пандемии коронавируса. На этой неделе можно было наблюдать, например, такие публикации:

«Эффект распространения коронавирусной инфекции приведет к ухудшению качества банковских активов...»;

«Аналитики фиксируют начавшееся в конце марта быстрое снижение экономической активности, которое по итогам года может обернуться падением выпуска товаров и услуг на 4–6%...»;

«Закрытие непродовольственных магазинов, залов кафе и ресторанов привело к снижению трафика московских торговых центров более чем на 70%».

Признак	Значение	Вклад	Влияние
<i>moeх</i>	1.23	0.08	+
<i>infl_lag_1</i>	0.24	0.07	+
<i>infl_lag_2</i>	0.24	0.04	+
<i>infl_lag_6</i>	-0.02	0.01	-
<i>neg_news_range</i>	0.23	0.01	+
<i>infl_lag_3</i>	0.05	0.01	-

Таблица 7. Интерпретация прогноза Random Forest методом LIME для случая ковидного шока (представлены признаки с наибольшим влиянием)

Источник: расчеты автора

В данном случае можно заметить, что текстовая переменная *neg_news_range* (разница между максимумом и минимумом за неделю), является четвертым по положительному вкладу в прогноз признаком, уступая только нескольким лагам инфляции и индексу Мосбиржи. В то же время переменная опережает по вкладу, например, третий лаг инфляции, что подчеркивает, насколько полезную информацию она может передавать данной модели.

Далее по аналогии была рассмотрена неделя по 4 марта 2022г., связанная с началом СВО (см. таблицу 5). В этом случае список наиболее важных переменных во многом похож на предыдущий, а в топ-5 показателей по положительному влиянию снова входит текстовая переменная, но на этот раз уже связанная с токсичностью комментариев. Из изменений здесь также появляется ставка MIACR, которая в тот период сильно выросла.

Признак	Значение	Вклад	Влияние
<i>moex</i>	15.76	0.08	+
<i>infl_lag_1</i>	0.46	0.08	+
<i>infl_lag_2</i>	0.34	0.03	+
<i>miacr</i>	10.83	0.02	+
<i>com_tox_range</i>	0.53	0.01	+
<i>infl_lag_18</i>	0.27	0.01	+

Таблица 8. Интерпретация прогноза Random Forest методом LIME для случая начала СВО (представлены признаки с наибольшим влиянием).

Источник: расчеты автора

Также для примера были рассмотрены наблюдения из тестовой выборки 2025г (табл. 6). Здесь представлены две недели: с относительно высокой (0.16% на неделе по 24 марта) и низкой (0.004% на неделе по 28 июля) инфляцией с учетом сезонности.

17/24-03-2025			21/28-07-2025		
Признак	Вклад	Влияние	Признак	Вклад	Влияние
<i>infl_lag_1</i>	0.05	+	<i>infl_lag_1</i>	0.06	-
<i>dollar_lag_3</i>	0.01	-	<i>infl_lag_2</i>	0.01	-
<i>infl_lag_3</i>	0.01	+	<i>infl_lag_6</i>	0.01	-
<i>pos_news_range</i>	0.01	+	<i>infl_lag_3</i>	0.01	+
<i>gas</i>	0.01	+	<i>gas</i>	0.01	+
<i>miacr_lag_8</i>	0.01	-	<i>dollar_lag_3</i>	0.01	+

Таблица 9. Интерпретация прогнозов Random Forest методом LIME на тестовой выборке (представлены признаки с наибольшим влиянием)

Источник: расчеты автора

Из таблицы видно, что *pos_news_range* является третьим по положительному вкладу признаком в случае с высокой инфляцией. В то же

время для кейса околонулевой инфляции текстовые переменные не оказывают сильного влияния на прогноз, модель в основном опирается на предыдущие значения целевой переменной, а также в меньшей степени на цены на газ и курса доллара.

Рассмотренные случаи позволяют сделать вывод о том, что новые переменные на основе сентимента действительно чаще используются моделью в периоды различных шоков и высокой инфляции. На это также указывает тот факт, что модель чаще обращает внимание именно на негативный сентимент (токсичность, высокую долю негативных новостей и низкую долю положительных). Причем модель может учитывать разные признаки: в случае с пандемией COVID-19 более важной оказалась информация из текстов новостей, а после начала СВО - из комментариев. В то же время в более стабильные периоды текстовые переменные не несут такой пользы. Здесь модель больше ориентируется на макропеременные: в первую очередь, на лаги самой инфляции, а также на индекс Мосбиржи, процентные ставки и сезонные дамми-переменные.

7 Заключение

Таким образом, исследование было разделено на несколько частей. Во-первых, удалось обучить модель для извлечения сентимента из текстов новостных публикаций с точностью 0.76 на тестовой выборке. Данная модель отличается от остальных тем, что учитывает новостную и экономическую специфику, а также извлекает смысловой сентимент, а не просто эмоциональную окраску.

Далее было показано, что основанные на текстовой информации признаки могут статистически значимо улучшать качество прогноза. Особенно полезными данные признаки оказываются для ансамблевых ML-моделей (в каких-то случаях снижение ошибки достигало 13%), что может говорить о нелинейном характере влияния. Основная польза этих переменных заключается в способности указывать на различные шоковые колебания в экономике, что подтвердилось при проверке устойчивости результатов, а также на этапе локальной интерпретации.

Также оказалось, что ML-модели превосходят по качеству эконометрические бенчмарки. Это подтверждает гипотезу о том, что, при условии достаточно большого количества наблюдений и объясняющих переменных, ML-модели могут быть наиболее предпочтительными за счет возможности описывать более сложные зависимости в данных. Однако такой вывод нужно делать с осторожностью, так как во многих случаях использовался уровень значимости 0.1, что может быть оправдано в условиях небольшого количества наблюдений в тестовой выборке.

Кроме того, исследование результатов по кварталам и на разных горизонтах прогнозирования позволило получить ряд дополнений к предыдущим результатам. Квартальный анализ показал, что в окрестности сильных сдвигов инфляции (начало 2022г.) текстовые признаки сначала ухудшают качество, однако далее, когда таких примеров становится больше в обучающей выборке волатильность целевой переменной не мешает снижению ошибки (в качестве примера был рассмотрен 2025г.). Также при

квартальном рассмотрении подтвердилась особенно выраженная польза от учета текстового сентимент-анализа для ML-моделей, однако зачастую она была нестабильной на протяжении всего года и достигалась за счет отдельных периодов. Похожий эффект наблюдался и в случае с разными горизонтами прогнозирования: почти всегда снижение ошибки после добавления новых признаков зависело от конкретного горизонта и года для разных моделей. Однако в целом также можно было наблюдать более стабильные улучшения для краткосрочных прогнозов и более сильные, но менее стабильные - для долгосрочных.

В заключение следует отметить, что исследование решает сразу две проблемы: с одной стороны, рассматривается актуальный период (2015-2025гг.) без сильных структурных сдвигов, но в то же время поддерживается большое количество наблюдений за счет недельной частоты данных. В таких условиях появляется возможность обучать сложные нелинейные модели, качество которых было улучшено при помощи учета текстов новостей и комментариев. Результатом работы является модель прогнозирования инфляции, которую можно использовать в будущем. В режиме реального времени в течение недели можно собирать доступные макропеременные, а также тексты новостей и комментариев к ним и оценивать уровень инфляции к концу недели. Кроме того, можно получать объяснение прогноза в конкретной точке при помощи методов локальной интерпретации, что может быть полезно для центральных банков и государственных органов, так как это обеспечивает прозрачность прогнозов и помогает обосновывать принимаемые экономические решения.

СПИСОК ЛИТЕРАТУРЫ

- 1) Байбуза, И. (2018). Прогнозирование инфляции с помощью методов машинного обучения. *Деньги и кредит*, (4), 42-59.
- 2) Волгина, Е. (2025). Прогнозирование инфляции с использованием новостных индексов. *ДЕНЬГИ И КРЕДИТ*, 84(1), 26-59.
- 3) Aikman, D., & Barwell, R. (2025). Reactions to the Bernanke Review from Bank of England watchers. *International Journal of Forecasting*.
- 4) Allard, M. A., Telletche, P., & Zinebi, A. (2024). Enhancing inflation nowcasting with llm: Sentiment analysis on news. *arXiv preprint arXiv:2410.20198*.
- 5) Aras, S., & Lisboa, P. J. (2022). Explainable inflation forecasts by machine learning models. *Expert Systems with Applications*, 207, 117982.
- 6) Ashwin, J., Kalamara, E., & Saiz, L. (2024). Nowcasting euro area GDP with news sentiment: a tale of two crises. *Journal of Applied Econometrics*, 39(5), 887-905.
- 7) Barbaglia, L., Consoli, S., & Manzan, S. (2023). Forecasting with economic news. *Journal of Business & Economic Statistics*, 41(3), 708-719.
- 8) Devlin, J., Chang, M. W., Lee, K., & Toutanova, K. (2019, June). Bert: Pre-training of deep bidirectional transformers for language understanding. In *Proceedings of the 2019 conference of the North American chapter of the association for computational linguistics: human language technologies, volume 1 (long and short papers)* (pp. 4171-4186).
- 9) Eugster, P., & Uhl, M. W. (2024). Forecasting inflation using sentiment. *Economic Letters*, 236, 111575.
- 10) Joseph, A., Potjagailo, G., Kalamara, E., Chakraborty, & C., Kapetanios G. (2024). Forecasting UK inflation bottom up. *International Journal of Forecasting*, 40(4), 1521-1538.
- 11) Li, X., & Tang, Z. (2022). Sentiment analysis on inflation after COVID-19. *arXiv preprint arXiv:2209.14737*.

- 12) Li, J., Xu, Z., Yu, L., & Tang, L. (2016). Forecasting oil price trends with sentiment of online news articles. *Procedia Computer Science*, 91, 1081-1087.
- 13) Medeiros, M. C., Vasconcelos, G. F., Veiga, Á., & Zilberman, E. (2021). Forecasting inflation in a data-rich environment: the benefits of machine learning methods. *Journal of Business & Economic Statistics*, 39(1), 98-119.
- 14) Pinson, P. (2026). Editorial and introduction to the special section on the Bernanke's review of the Bank of England's forecasting activities. *International Journal of Forecasting*, 42(1), 1-2.
- 15) Rambaccussing, D., & Kwiatkowski, A. (2020). Forecasting with news sentiment: Evidence with UK newspapers. *International Journal of Forecasting*, 36(4), 1501-1516.
- 16) Seo, B. (2025). Econometric forecasting using ubiquitous news text: Text-enhanced factor model. *International Journal of Forecasting*, 41(3), 1055-1072.
- 17) Sharpe, S. A., Sinha, N. R., & Hollrah, C. A. (2023). The power of narrative sentiment in economic forecasts. *International Journal of Forecasting*, 39(3), 1097-1121.
- 18) Simionescu, M. (2025). Machine learning vs. econometric models to forecast inflation rate in Romania? The role of sentiment analysis. *Mathematics*, 13(1), 168.
- 19) Simionescu, M. (2022). Econometrics of sentiments-sentometrics and machine learning: The improvement of inflation predictions in Romania using sentiment analysis. *Technological Forecasting and Social Change*, 182, 121867.
- 20) Tilly, S., Ebner, M., & Livan, G. (2021). Macroeconomic forecasting through news, emotions and narrative. *Expert Systems with Applications*, 175, 114760.
- 21) Росстат. Новости статистики. - URL: (<https://rosstat.gov.ru/central-news>)
- 22) Коммерсантъ. Сообщество ВКонтакте «Коммерсантъ Экономика» [Электронный ресурс]. - URL: (<https://vk.com/kommersant.economics>)
- 23) Интерфакс. Новости экономики [Электронный ресурс]. - URL: (<https://www.interfax.ru/business/>)
- 24) Центральный банк Российской Федерации. Базы данных. - URL: (https://www.cbr.ru/hd_base/)

- 25) Investing.com. Индекс МосБиржи (ММВБ). - URL:
(<https://ru.investing.com/indices/mcx>)
- 26) Federal Reserve Bank of St. Louis. FRED Economic Data. Commodities. -
URL: (<https://fred.stlouisfed.org/categories/32217>)
- 27) Hugging Face. rubert-tiny2-russian-sentiment [Электронный ресурс]. - URL:
(<https://huggingface.co/seara/rubert-tiny2-russian-sentiment>)
- 28) Hugging Face. s-nlp/russian_toxicity_classifier [Электронный ресурс]. -
URL: (https://huggingface.co/s-nlp/russian_toxicity_classifier)